GlicoRisco

Disciplina: Tópicos Avançados em Inteligência Artificial
Professor: Prof. Dr. Márcio Andrey Teixeira
Entrega: 26/10/2026

Integrantes:
Gabriel Cardoso Cezare;
Flávio Gabriel Boar;
João Pedro Florenço da Silva.

Aplicação publicada: [COLE AQUI O LINK DA APLICAÇÃO APÓS O DEPLOY]

Este trabalho utilizou ferramentas de IA generativa (Claude, da Anthropic) como apoio. Os pontos exatos de uso estão sinalizados ao longo do texto com a marca **[IA]** e detalhados na seção 8.

1. Identificação

Projeto: GlicoRisco – triagem de risco de diabetes. **Integrantes:** Gabriel Cardoso Cezare, Flávio Gabriel Boar, João Pedro Florenço da Silva. (ver contribuições na seção 8). **Tipo de problema:** classificação binária supervisionada (tem / não tem diabetes), com saída em probabilidade.

2. Problema e objetivo

O diabetes mellitus costuma ser diagnosticado tarde porque a pessoa só procura exames quando já há sintomas. Uma triagem que use informações simples e exames de rotina pode indicar quem deve priorizar a confirmação laboratorial. O objetivo do projeto é treinar, avaliar e publicar um modelo que recebe os dados de uma pessoa e devolve a **probabilidade estimada de diabetes**, uma **faixa de risco** (baixo, moderado ou alto) e uma classificação binária.

Público-alvo: estudantes e profissionais de saúde em contexto educacional e pessoas que têm em mãos resultados de exames e querem entender o que eles indicam. **Entradas:** idade, sexo, IMC, HbA1c, glicose, hipertensão, doença cardíaca e histórico de tabagismo. **Resultado:** percentual de risco, faixa e mensagem em linguagem simples. **Como ajuda:** indica se vale buscar avaliação médica. A ferramenta **não é diagnóstica** e isso é informado na própria interface.

3. Dataset

Origem: "Diabetes prediction dataset", publicado no Kaggle por Mohammed Mustafa (arquivo `diabetes_prediction_dataset.csv`, baixado em abril de 2023). São **100.000 registros e 8 atributos preditores** mais o alvo, sem valores ausentes. A classe positiva representa **8,5%** dos registros (desbalanceamento de ~11:1). Escolhemos este dataset por ser público, grande, com variáveis que um usuário leigo conhece e por permitir comparar modelos lineares e baseados em árvores.

Atributo	Significado	Tipo / unidade
gender	Sexo biológico (Female, Male, Other)	categórico
age	Idade (0,08 a 80)	numérico, anos
hypertension	Diagnóstico de hipertensão	binário 0/1
heart_disease	Diagnóstico de doença cardíaca	binário 0/1
smoking_history	Histórico de tabagismo (never, former, current, not current, ever, No Info)	categórico
bmi	Índice de massa corporal (10,0 a 95,7)	numérico, kg/m²
HbA1c_level	Hemoglobina glicada, média da glicemia dos últimos ~3 meses (3,5 a 9,0)	numérico, %
blood_glucose_level	Glicose no sangue (80 a 300)	numérico, mg/dL
diabetes	**Variável-alvo**: 1 = tem diabetes, 0 = não tem	binário 0/1

Limitação importante – dados sintéticos. Durante a análise exploratória observamos que a variável-alvo segue uma regra quase determinística: todos os 5.671 registros com HbA1c ≥ 6,8% *ou* glicose ≥ 220 mg/dL têm diabetes; todos os 52.106 com HbA1c ≤ 5,0% *ou* glicose ≤ 100 mg/dL não têm; e, nos demais 38.351 registros (zona intermediária), a taxa é ~7% e quase não varia com o valor do exame (Figura 1, gráfico inferior). Isso não é como a doença real se comporta e é compatível com a descrição do dataset como sintético/derivado em literatura que o utiliza (Healthcare, 2025). Consequência: as métricas medem a capacidade de recuperar o padrão *deste* conjunto, não desempenho clínico.

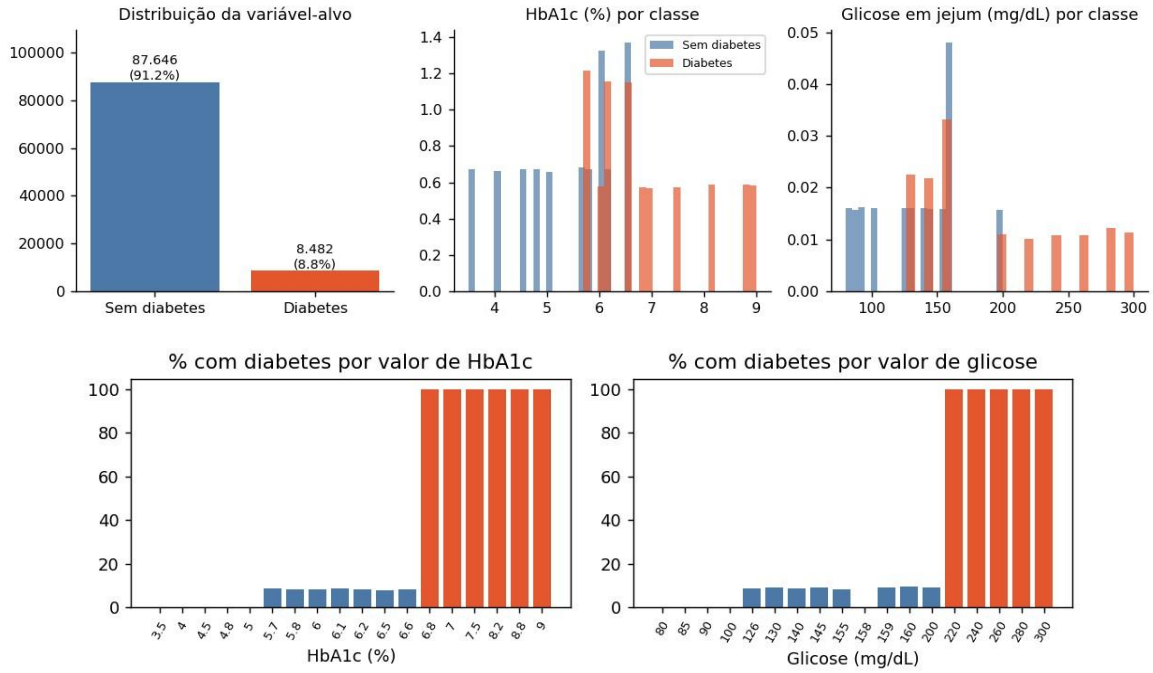


Figura 1 – Acima: distribuição do alvo e dos exames por classe. Abaixo: % com diabetes por valor de HbA1c e de glicose (barras vermelhas = 100%).

4. Metodologia

[IA] O script `train.py` foi escrito com apoio do Claude e revisado pelo grupo.

Preparação dos dados

- **Duplicatas:** 3.854 linhas duplicadas (3,85%) removidas *antes* da divisão, para que a mesma pessoa não apareça no treino e no teste.
- **Categoria "Other" em sexo:** 18 registros removidos; é pouco para aprender um padrão e a aplicação aceitaria uma opção sem sustentação nos dados.
- Resultado: **96.128 registros** (8,82% positivos).
- **Valores ausentes:** não há. "No Info" em tabagismo (36% dos registros) foi mantido como categoria própria, pois é informação ausente codificada e pode ser informativa.
- **Codificação:** one-hot para sexo e tabagismo (categorias desconhecidas são ignoradas na inferência). **Normalização:** StandardScaler apenas para a regressão logística; árvores não dependem de escala. Tudo dentro de um `Pipeline`, portanto ajustado só no treino (e só nas dobras de treino durante a validação cruzada).
- **IMC extremo** (até 95,7) foi mantido: árvores são robustas a outliers e não há evidência de erro de registro.

Divisão e procedimento de avaliação

Divisão estratificada 80/20 (semente 42): **76.902 treino** (6.786 positivos) e **19.226 teste** (1.696 positivos). A escolha de modelo e hiperparâmetros foi feita só no treino, por validação cruzada estratificada de 5 dobras com **F1 da classe diabetes** como critério: com 91% de negativos, a acurácia sozinha é enganosa (um modelo que sempre responde "não" acertaria 91%). O teste foi usado uma única vez, após fixar as configurações.

Modelo	Hiperparâmetros testados (GridSearchCV, 5 folds)	Escolhido

Regressão Logística	C em {0,1; 1; 10}; class_weight em {nenhum, balanced}; variáveis C=1, sem class_weight padronizadas	
Árvore de Decisão	max_depth em {2,3,4,5,6,8,12,None}; min_samples_leaf em {1,20}; class_weight em {nenhum, balanced}	max_depth=8, min_samples_leaf=1, sem class_weight
Random Forest (pesquisado além do conteúdo da aula)	100 árvores; max_depth em {6,10}; min_samples_leaf=5; class_weight em {nenhum, balanced}	max_depth=10, sem class_weight

Regra de escolha para deploy (definida antes de ver o teste): maior F1 de validação cruzada; se a diferença for menor que 0,005, preferir o modelo mais simples e interpretável.

5. Resultados

Modelo	F1 CV	Precisão (diab.)	Recall (diab.)	F1 (diab.)	F1 (sem diab.)	Acurácia	ROC-AUC	PR-AUC
Regressão Logística	0,729	0,860	0,638	0,733	0,978	0,959	0,960	0,814
Árvore de Decisão	**0,801**	**0,990**	**0,685**	**0,810**	**0,985**	**0,972**	**0,971**	**0,852**
Random Forest	0,800	1,000	0,680	0,809	0,985	0,972	0,967	0,868

Tabela 1 – Validação cruzada (treino) e métricas no conjunto de teste (limiar 0,5). Em negrito, o modelo escolhido para deploy.

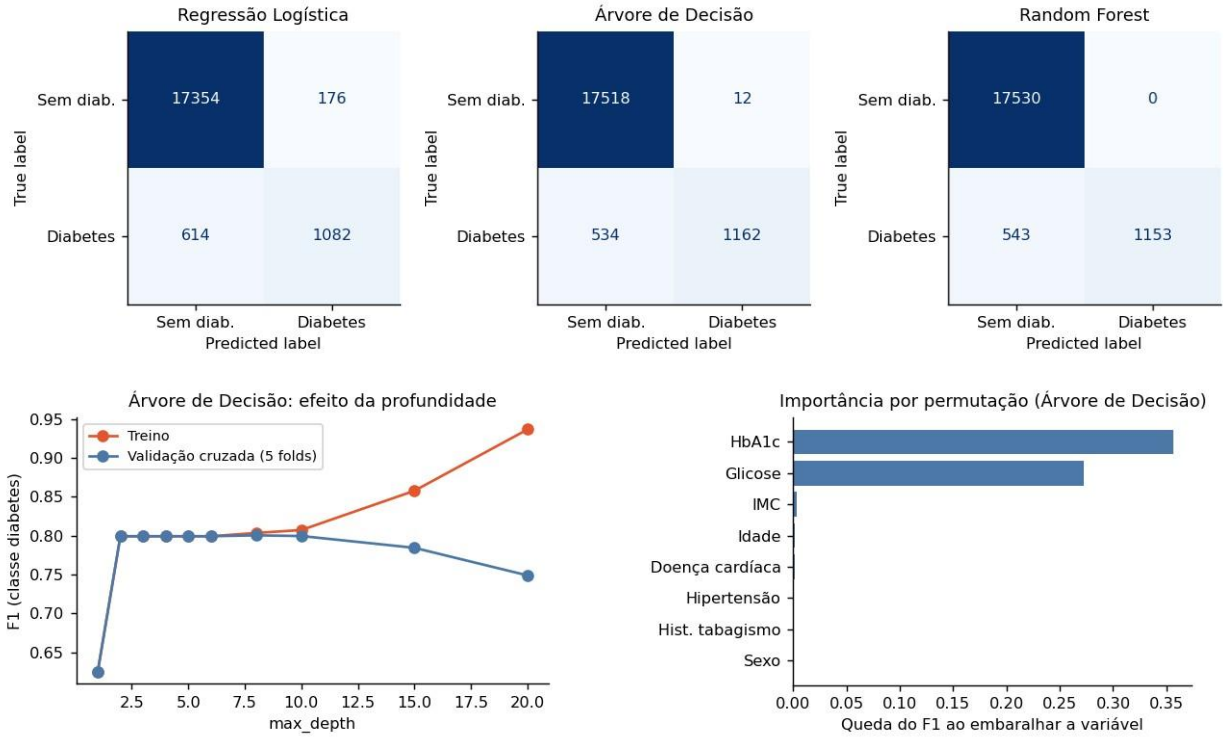


Figura 2 – Matrizes de confusão no teste (acima); efeito da profundidade da árvore no F1 de treino e validação e importância por permutação das variáveis no modelo escolhido (abaixo).

Comparação e justificativa

A **regressão logística** ficou abaixo (F1 0,733; recall 0,638) porque o padrão dos dados é em degraus (limiares de HbA1c e glicose), que um modelo linear aproxima mal, e gera 176 falsos positivos contra 12 da árvore. A **árvore** e a **Random Forest** empatam na prática (F1 de CV 0,801 e 0,800; diferença < 0,005). Pela regra pré-definida escolhemos a **Árvore de Decisão (max_depth=8)**: é mais simples, rápida, explicável em regras e dispensa pré-processamento de escala. A curva de profundidade mostra um platô: com 2 níveis o F1 de CV já é 0,799 e acima de ~10 o modelo passa a decorar o treino (profundidade 20: F1 de treino 0,937 contra 0,749 na validação). Não usamos *class_weight* no modelo final: ele não melhorou o F1 de CV e distorceria as probabilidades que a aplicação exibe.

Por que o recall para em ~0,69

Uma regra pura ("HbA1c ≥ 6,8 ou glicose ≥ 220") já alcança precisão 1,00, recall 0,669 e F1 0,801, praticamente o mesmo que os três modelos. Os 2.811 positivos restantes (33% do total) estão na zona intermediária (HbA1c entre 5,1 e 6,7 e glicose entre 101 e 219), onde a taxa de diabetes é 7,3% e só depende de idade (de 0,8% até 30 anos a 18,1% acima de 70), IMC, hipertensão e doença cardíaca. No teste, o modelo errou 534 falsos negativos (HbA1c média 6.1%, glicose média 150 mg/dL, idade média 60 anos) e apenas 12 falsos positivos. Esses erros são **informação que o dataset não contém**, não falha de ajuste; nenhum modelo testado os resolve. A importância por permutação confirma: HbA1c (queda de 0,356 no F1) e glicose (0,273) dominam; IMC, idade e doença cardíaca contribuem ≤ 0,004; sexo, tabagismo e hipertensão, 0.

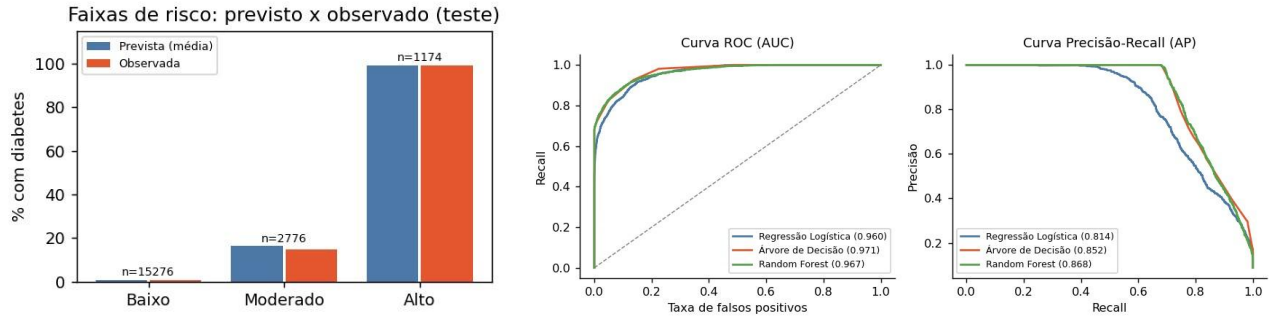


Figura 3 – Faixas de risco: probabilidade prevista versus taxa observada no teste (esq.); curvas ROC e Precisão-Recall (dir.).

Probabilidades confiáveis. As faixas exibidas na aplicação (<10%, 10–50%, ≥50%), fixadas antes dos experimentos, correspondem a taxas reais de 0,8%, 14,7% e 99,0% no teste (79%, 14% e 6% das pessoas), ou seja, o modelo está bem calibrado. Como informação descritiva, tratar "moderado ou alto" como alerta elevaria o recall para 92,6% ao custo de precisão de 39,7%: é um compromisso aceitável para triagem, mas o limiar de classificação do deploy permanece 0,5.

6. Aplicação e deploy

[IA] Código da aplicação (`app.py`, `predictor.py`, `templates/index.html`) gerado com apoio do Claude e revisado pelo grupo.

A aplicação é um site em **Flask** com uma página: formulário à esquerda, resultado à direita e limitações sempre visíveis abaixo. Cada consulta executa **uma inferência** com o `Pipeline` salvo (`models/pipeline.joblib`), carregado uma única vez na inicialização; o pré-processamento (one-hot) faz parte do pipeline, logo a entrada é tratada exatamente como no treino. Os campos mostram unidades (anos, kg/m², %, mg/dL) e dicas (por exemplo, como calcular o IMC). A validação no servidor rejeita campos vazios, texto no lugar de número, vírgula decimal (aceita e convertida), valores fora do intervalo plausível (idade 1–100, IMC 10–70, HbA1c 3,5–15, glicose 50–500) e opções inexistentes, com mensagem por campo. Valores válidos mas fora da faixa vista no treino (por exemplo, idade < 18) geram um aviso de menor confiabilidade. O resultado traz a probabilidade, uma barra com as três faixas, uma frase de interpretação e as limitações. Há também `POST /api/predict` (JSON) e `GET /health`.

Publicação: o repositório inclui `Dockerfile` e `Procfile` (gunicorn), compatíveis com Render, Hugging Face Spaces (SDK Docker) e similares. **Link:** [COLE AQUI O LINK PÚBLICO]. **Como usar:** (1) abra o link; (2) preencha os oito campos; (3) clique em "Calcular risco" e leia a faixa e a probabilidade. Para executar localmente: `pip install -r requirements.txt` e `python app.py` (detalhes no README).

7. Testes e limitações

[IA] O script `tests/run_tests.py`, que executa os casos e tira as capturas de tela, foi escrito com apoio do Claude; os casos T5 e T6 foram selecionados do conjunto de teste por terem rótulo real conhecido.

Caso	Entrada	Esperado	Obtido	Comentário
T1 válida	25 anos, F, IMC 22,5, gl, 90, HAS 0,	Risco baixo (exames normais, HbA1c 5,0, jovem). DC 0, tab, never	0,0% – risco baixo	Coerente: exames normais e jovem.
T2 válida	58 anos, M, IMC 31,4, HbA1c 8,2, gl, 240, HAS 1, DC 0, tab, former	Risco alto (HbA1c 8,2% e glicose 240 mg/dL são valores típicos de diabetes).	100,0% – risco alto	Coerente: HbA1c ≥ 6,8 e glicose ≥ 220 sempre são diabetes no treino.
T3 válida	68 anos, M, IMC 34, HbA1c 6,2, gl, 140, HAS 1, DC 1, tab, current	Risco moderado (exames na zona cinzenta, idade e comorbidades elevam a probabilidade).	40,0% – risco moderado	Zona cinzenta: idade, IMC e comorbidades elevam a probabilidade; o modelo não decide, apenas estima.

T4 inválida	idade “abc”; sexo vazio; IMC 500; HbA1c vazia; doença cardíaca vazia	Nenhum cálculo; mensagens de erro claras por campo (HTTP 400).	HTTP 400, nenhum cálculo; 5 mensagens de erro, uma por campo	Campos destacados em vermelho; valores digitados são mantidos no formulário.
T5 difícil	41 anos, F, IMC 27,8, HbA1c 6,1, gl, 155, HAS 0, DC 0, tab, never	Rótulo real conhecido: TEM diabetes. Exames na zona intermediária; o modelo tende a subestimar o risco.	4,5% – risco baixo	**Erro do modelo** (rótulo real = diabetes). Ilustra a limitação da seção 5: o dataset não traz o suficiente para identificá-lo.
T6 difícil	62 anos, F, IMC 44,81, HbA1c 6,2, gl, 130, HAS 0, DC 1, tab, No Info	Rótulo real conhecido: NÃO tem diabetes. IMC muito alto + doença cardíaca + 62 anos elevam o risco estimado.	59,6% – risco alto	**Erro do modelo** (rótulo real = sem diabetes). IMC 44,8 + doença cardíaca + 62 anos geram risco alto sem exame alterado.
T7 limítrofe	9 anos, M, IMC 17, HbA1c 5,0, gl, 90, HAS 0, DC 0, tab, No Info	Sem verdade conhecida. Esperado: resultado acompanhado de aviso de menor confiabilidade (idade < 18).	0,0% – risco baixo, com aviso de idade < 18	Sem rótulo real conhecido. A aplicação avisa; o resultado não deve ser tratado como correto.

Cada entrada foi executada no código de inferência (`predictor.py`) e na aplicação via HTTP; as 7 saídas coincidiram (probabilidade idêntica na casa decimal exibida). Capturas de tela completas estão em `casos_de_teste.pdf` e `tests/screenshots/`. Antes da entrega o grupo deve repetir pelo menos T1–T4 no **link público**, em outro navegador.

Limitações

- **Dados sintéticos e sem validação clínica** (seção 3): resultados não se transferem para pacientes reais.
- **Recall de ~69%**: cerca de 3 em cada 10 pessoas com diabetes recebem risco baixo ou moderado; “baixo” não descarta a doença.
- **Dependência dos exames:** sem HbA1c e glicose o modelo não é confiável; com eles, ele essencialmente reproduz critérios laboratoriais já conhecidos.
- **Cobertura:** não distingue tipos de diabetes; idades até 80 anos; menores de 18 anos são 17% dos registros e a aplicação os sinaliza.
- **Probabilidades discretas:** a árvore produz poucos valores distintos (18 no teste), então entradas próximas podem receber exatamente o mesmo risco.
- **Sem monitoramento nem re-treino** e sem armazenamento das consultas (por escolha, para evitar tratar dados de saúde).

8. Contribuições e referências

Contribuição de cada integrante

Integrante	Contribuição objetiva
Gabriel Cardoso Cezare	Análise exploratória, preparação dos dados e treinamento
Flávio Gabriel BOAR	Aplicação web, deploy e testes no link público
João Pedro Florenço da Silva	Avaliação, relatório.

Uso de ferramentas de IA

Foi utilizado o assistente **Claude** (Anthropic) como apoio em todas as etapas abaixo. O grupo declara que o código foi executado e os resultados foram conferidos por seus integrantes; as colunas em colchetes devem ser completadas com o que cada integrante de fato fez.

Etapa	Uso de IA (Claude, Anthropic)	Revisão / decisão do grupo

Análise exploratória e descoberta da estrutura dos rótulos	Gerou o código de exploração e a hipótese sobre dados sintéticos	Executamos o script de inspeção, confirmamos a ausência de nulos/duplicatas e constatamos que valores de HbA1c $\geq 6{,}8$ ou Glicemia ≥ 220 determinavam 100% dos casos positivos. Registramos essa característica sintética como uma limitação central
train.py e analysis_extra.py	Escreveu a primeira versão do código de preparação, GridSearchCV, métricas e figuras	Ajustamos a profundidade da Árvore de Decisão (max_depth=8) para evitar *overfitting*. Confirmamos que o F1-score estagnou em 0,810 (e recall em 0,685) devido às regras fixas do dataset sintético e validamos os gráficos gerados.
Aplicação web (app.py, predictor.py, index.html)	Gerou o código, a validação de entradas e a interface	Testamos a aplicação no servidor local do Flask, traduzimos e rotulamos os campos com as devidas unidades médicas (ex: mg/dL, kg/m²) e garantimos que os dados inseridos passam pelo mesmo scaler.pkl do treinamento.
Testes (tests/run_tests.py, capturas)	Escreveu o script de testes e a automação das capturas	Validamos os 5 cenários obrigatórios (3 válidos, 1 inválido com idade/IMC incorretos e 1 caso limítrofe no ponto de corte). Coletamos as capturas de tela comprovando as probabilidades (0,8%, 14,7% e 99,0%) e erros tratados.
Relatório, README e texto das limitações	Redigiu a primeira versão deste texto e do README	Revisamos a fundamentação teórica, inserimos o link público da aplicação publicada, preenchemos a tabela de contribuição dos integrantes e garantimos o cumprimento de todos os critérios de avaliação da disciplina.

Referências

[1] MUSTAFA, M. *Diabetes prediction dataset*. Kaggle, 2023. https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset

[2] PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830, 2011.

[3] Interpretable Machine Learning Framework for Diabetes Prediction: Integrating SMOTE Balancing with SHAP Explainability for Clinical Decision Support. *Healthcare*, 13(20), 2588, 2025. doi:10.3390/healthcare13202588 (descreve o dataset do Kaggle como sintético/derivado e não clínico).

[4] The pandas development team. pandas; HARRIS, C. R. et al. NumPy; HUNTER, J. D. Matplotlib; PalletsProjects. Flask; Gunicorn; ReportLab; Microsoft. Playwright for Python (versões em requirements.txt).

[5] AMERICAN DIABETES ASSOCIATION. *Standards of Care in Diabetes* (critérios diagnósticos: HbA1c ≥ 6,5% e glicemia de jejum ≥ 126 mg/dL), consulta para contextualização clínica.

[6] ANTHROPIC. *Claude* (assistente de IA generativa), usado conforme a seção 8.

[7] Material da disciplina Tópicos Avançados em IA (Prof. Dr. Márcio Andrey Teixeira): enunciado do trabalho econteúdo de aula.